

Analisi Sperimentale della Clonazione della Propria Voce tramite Modelli Generativi per l'Individuazione degli Artefatti dei Deepfake Audio

Introduzione

L'evoluzione dei modelli generativi ha reso possibile sintetizzare voci umane con un livello di realismo sempre maggiore. Questa tecnologia presenta numerose applicazioni legittime, come l'accessibilità, il doppiaggio e gli assistenti vocali personalizzati, ma introduce anche nuovi rischi per la sicurezza informatica, in particolare nell'ambito dell'ingegneria sociale e delle frodi basate sull'identità vocale.

L'obiettivo di questa attività sperimentale è analizzare il comportamento di un sistema di clonazione vocale utilizzando esclusivamente la propria voce, al fine di identificare gli artefatti acustici prodotti dall'intelligenza artificiale e comprenderne le implicazioni dal punto di vista della sicurezza.

Obiettivi

L'esperimento si propone di:

- comprendere il funzionamento generale della clonazione vocale mediante IA;
 - confrontare registrazioni autentiche e sintetizzate;
 - individuare gli indicatori che consentono di riconoscere un deepfake audio;
 - valutare i limiti tecnologici dei modelli generativi attuali;
 - riflettere sulle possibili contromisure adottabili in ambito aziendale.
-

Materiali

Per l'esperimento sono necessari:

- un microfono di buona qualità;
 - un ambiente silenzioso per la registrazione;
 - una serie di brevi registrazioni della propria voce;
 - un software di analisi audio (ad esempio `entity["software", "Audacity", "audio editor"]`);
 - un modello di sintesi vocale utilizzato esclusivamente per finalità didattiche e sulla propria voce.
-

Metodologia

1. Acquisizione della voce

Sono state registrate alcune frasi lette ad alta voce in ambiente controllato, cercando di mantenere:

- volume costante;
- distanza costante dal microfono;
- velocità di lettura uniforme;
- assenza di rumori ambientali.

Queste registrazioni costituiscono il campione di riferimento.

2. Generazione del campione sintetico

Le registrazioni vengono utilizzate esclusivamente per creare una versione sintetica della propria voce, senza coinvolgere altre persone e nel rispetto delle finalità didattiche dell'esercitazione.

Il contenuto generato viene limitato a frasi neutre e prive di qualsiasi intento di impersonificazione.

3. Analisi Comparativa

Successivamente vengono confrontati:

- il campione originale;
- il campione sintetizzato.

L'analisi considera sia l'ascolto soggettivo sia alcune caratteristiche acustiche osservabili tramite software.

Parametri Analizzati

Timbro

Si valuta quanto la voce sintetica riproduca il colore vocale originale.

Possibili anomalie:

- voce eccessivamente "pulita";
 - armoniche poco naturali;
 - perdita di espressività.
-

Prosodia

La prosodia comprende:

- ritmo;
- intonazione;
- pause;
- enfasi.

I modelli generativi possono produrre un'intonazione troppo uniforme oppure pause poco naturali.

Pronuncia

Vengono confrontati:

- consonanti;
- vocali;
- inflessioni;
- accenti.

Le differenze risultano spesso più evidenti nelle parole lunghe o poco frequenti.

Stabilità del Segnale

L'audio sintetico può presentare:

- variazioni improvvise di intensità;
 - piccoli artefatti digitali;
 - transizioni innaturali tra sillabe.
-

Spettrogramma

Attraverso l'analisi dello spettrogramma è possibile osservare eventuali differenze tra voce reale e sintetica.

Tra gli elementi di interesse figurano:

- distribuzione delle armoniche;
 - continuità delle formanti;
 - presenza di componenti ad alta frequenza;
 - rumore di fondo.
-

Risultati Attesi

L'esperimento può evidenziare alcune differenze ricorrenti.

Artefatti temporali

La voce sintetica tende ad avere pause regolari e una cadenza meno spontanea rispetto alla voce naturale.

Uniformità eccessiva

L'intonazione può risultare troppo lineare, con minore variabilità emotiva.

Respirazione

Le registrazioni autentiche contengono inspirazioni, esitazioni e piccole imperfezioni che spesso vengono eliminate o ricostruite artificialmente.

Frequenze alte

Alcuni modelli mostrano una minore naturalezza nella riproduzione delle frequenze più elevate.

Espressività

Le emozioni risultano generalmente meno credibili rispetto alla registrazione originale.

Implicazioni per la Cybersecurity

Dal punto di vista della sicurezza informatica, i deepfake vocali rappresentano una minaccia crescente.

Tra gli scenari di rischio figurano:

- frodi telefoniche;
- impersonificazione di dirigenti (voice phishing);
- aggiramento di procedure organizzative basate sul riconoscimento della voce;
- diffusione di contenuti audio manipolati.

L'esperimento evidenzia come il riconoscimento umano, da solo, possa non essere sufficiente a distinguere una registrazione autentica da una sintetica.

Per questo motivo è consigliabile adottare controlli aggiuntivi, quali autenticazione multifattore, procedure di verifica su canali indipendenti e sistemi automatici di rilevamento dei deepfake.

Conclusioni

L'attività sperimentale dimostra che la qualità raggiunta dai moderni modelli di sintesi vocale è elevata, ma persistono caratteristiche acustiche che possono essere utilizzate per distinguerli da registrazioni autentiche.

Dal punto di vista della cybersecurity, la migliore strategia difensiva consiste nel non affidarsi esclusivamente alla voce come elemento di autenticazione, ma nel combinarla con controlli tecnici e organizzativi.

L'esercizio permette di comprendere concretamente sia le potenzialità sia i limiti delle tecnologie di clonazione vocale, fornendo una base utile per lo sviluppo di future strategie di difesa contro i deepfake audio.